

Título: **Viés e Uso Responsável do ChatGPT no Ambiente Corporativo**

Público-alvo: **profissionais em contexto corporativo, iniciantes em IA generativa**

Objetivo do material: Capacitar o ChatGPT (Study Mode) a ensinar sobre os riscos de viés associados ao seu uso no ambiente corporativo.

Instruções para o ChatGPT ao usar este PDF no Study Mode

- Você deve atuar como instrutor de um curso de introdução ao ChatGPT para uso corporativo.
- Por meio do método socrático aborde o conteúdo deste texto com o aluno.
- Adapte a explicação ao nível do aluno sempre que ele disser que algo está difícil ou não conseguir responder corretamente.
- Use exemplos práticos no contexto corporativo (RH, marketing, jurídico, atendimento, gestão, etc.).
- Faça perguntas frequentes para checar entendimento.
- Ao final, faça um resumo dos principais conceitos e pergunte se o aluno quer responder um mini “quiz” de revisão.

Objetivos de aprendizagem

Ao final do estudo deste material, o aluno deve ser capaz de:

- Explicar o que é viés.
- Explicar porque existe o risco do ChatGPT gerar textos com viés.

Como o ChatGPT funciona

O ChatGPT é um programa de computador criado para gerar textos parecidos com os que nós, humanos, escrevemos e falamos.

Para isso, ele foi treinado com uma quantidade gigantesca de textos: livros, sites, artigos, notícias e até conversas. Ao analisar bilhões de frases, ele “aprendeu” padrões da linguagem — por exemplo, quais palavras costumam aparecer juntas, como as ideias são organizadas e quais respostas fazem sentido em diferentes situações.

É importante entender que o ChatGPT não “sabe” coisas como uma pessoa e não tem opiniões próprias. O que ele faz, na prática, é calcular, a cada momento, qual é a próxima palavra mais provável em uma frase, levando em conta tudo o que já foi escrito antes.

Isso pode parecer simples, mas, repetido muitas vezes em alta velocidade, acaba gerando textos que parecem muito naturais, como se ele estivesse “pensando” ou “conversando”.

Outro ponto importante:


- Em muitos casos, ele responde apenas com base no que aprendeu durante o treinamento, ou seja, usando o “conhecimento” que já foi gravado em seu modelo.
- Dependendo do que for solicitado o ChatGPT também pode consultar informações atualizadas na internet antes de responder, para trazer dados mais recentes.

O viés no ChatGPT

A inteligência artificial do ChatGPT foi treinada com textos produzidos por pessoas do mundo real. Por isso, ao gerar respostas, ele acaba refletindo, em alguma medida, formas de pensar, valores e até preconceitos presentes nesses materiais. Esse ponto é fundamental para compreender como e por que podem surgir vieses (tendências ou distorções) nas respostas do ChatGPT.

Na maior parte do tempo, ele utiliza apenas o conhecimento adquirido durante o treinamento. Entretanto, dependendo da pergunta e das configurações disponíveis, o ChatGPT também pode buscar informações atualizadas na internet antes de responder.

É importante destacar que nem todos os grupos sociais têm a mesma presença online ou estiveram igualmente representados nos textos usados no treinamento. Certos países, culturas, grupos sociais e áreas profissionais produzem muito mais conteúdo que outros. Como resultado, os textos que compõem o treinamento do ChatGPT acabam refletindo, de forma mais intensa, a visão dos grupos mais presentes nessas fontes.



Na *web*, algumas opiniões e crenças se tornam populares ou amplamente aceitas, seja por tradições culturais, normas sociais ou simplesmente por serem as mais difundidas. Essas opiniões acabam aparecendo com frequência nos dados que treinaram o modelo. Assim, o ChatGPT pode trazer essas visões como se fossem universais ou "verdadeiras", mesmo que sejam apenas o reflexo das vozes mais dominantes.

Isso não significa que o ChatGPT tenha uma "opinião" própria ou que esteja intencionalmente sendo parcial. Ele apenas reflete o que foi mais frequente nos dados disponíveis. Portanto, se a maioria dos textos segue uma linha de pensamento predominante, o modelo tende a reproduzir essas ideias, o que chamamos de viés em um modelo de IA.

Além disso, nem todos os assuntos foram abordados com a mesma profundidade ou frequência nos dados de treinamento. Para alguns tópicos, o ChatGPT teve acesso a muitas informações e perspectivas variadas, enquanto para outros, os dados foram mais limitados. Isso faz com que, em certos casos, ele não possa oferecer respostas tão completas e diversificadas.

O ChatGPT passa por esforços contínuos para minimizar o viés. Isso inclui a curadoria dos dados de treinamento, o uso de técnicas avançadas de ajuste e a revisão constante do desempenho do modelo. Esses esforços visam tornar as respostas mais justas e equilibradas, mas é importante lembrar que nenhum modelo de IA é completamente isento de viés.

Em resumo, o ChatGPT é uma poderosa ferramenta de processamento de linguagem natural, mas suas respostas são limitadas pelos dados com os quais foi treinado ou podem ser obtidos na internet. Embora ele ofereça uma vasta gama de

informações, é essencial reconhecer que ele reflete as vozes mais predominantes. Isso pode introduzir algum viés em suas respostas. Portanto, use o ChatGPT com senso crítico e sempre confronte suas respostas com outras fontes, buscando diferentes perspectivas.